

ScikitLearn 操作記錄單 3

組別: 10 學號: 41247008S 姓名: 鄭兆宏

Unsupervised Learning

1. Clustering Module Function

Sklearn.cluster KMeans()

程式碼:

```
kmeans = KMeans(n_clusters=3, random_state=42)
kmeans_labels = kmeans.fit_predict(data_scaled)
print(f"KMeans Inertia: {kmeans.inertia_:.2f}")
```

結果: Inertia: 5702.87 **說明:** KMeans 執行速度快，Inertia 數值反映了群內緊密度。

Sklearn.cluster AgglomerativeClustering()

程式碼:

```
agg = AgglomerativeClustering(n_clusters=3)
agg_labels = agg.fit_predict(data_scaled)
```

說明: 階層式分群，結果與 KMeans 類似，但計算較慢。

Sklearn.cluster DBSCAN()

程式碼:

```
dbscan = DBSCAN(eps=2.0, min_samples=5)
dbscan_labels = dbscan.fit_predict(data_scaled)
```

說明: 參數敏感。eps=2.0 時只分出一群主要群聚，其餘為雜訊，顯示資料密度分佈均勻。

2. Clustering Evaluation

Sklearn.metrics.cluster normalized_mutual_info_score()

說明: 本次使用 Spotify 資料集無 Ground Truth，故無法計算 NMI。

Sklearn.metrics.cluster silhouette_score()

程式碼:

```
sil_score = silhouette_score(data_scaled, kmeans_labels)
```

結果:

- KMeans: 0.15
- Agglomerative: 0.20
- DBSCAN: 0.44 (僅一群)

說明: 分數偏低 (0.15~0.2) 表示歌曲風格界線模糊。DBSCAN 分數高是因為排除了鬆散點。

3. 音樂資料集分群報告

資料來源: Kaggle "Top Spotify Songs 2023" ([spotify-2023.csv](#)) **特徵:** bpm, danceability_%, energy_% 等音樂特徵。**前處理:** 移除缺失值，使用 `StandardScaler` 標準化。

分析:

1. **KMeans / Agglomerative:** 將歌曲分為 3 類，推測為「舞曲」、「慢歌」與「中間值」。
2. **DBSCAN:** 難以區分邊界，適合用於找離群值。
3. **結論:** KMeans 最適合此類資料。

程式碼連結: https://github.com/twdanielcheng112/Data-Mining-HW10/blob/main/solve_hw10.py

視覺化結果:

